Analiza i prepoznavanje bolesti biljaka

E2 12/2025 Sanja Radić, E2 13/2025 Srđan Ilić, E2 67/2025 Stefan Lazarević

1. Definicija problema

Cilj ovog projekta je razvoj modela zasnovanog na dubokom učenju koji automatski identifikuje vrstu biljke i prepoznaje specifičnu bolest na osnovu digitalne fotografije lista. Problem se definiše kao zadatak klasifikacije slika, gde model na ulazu prima *RGB* sliku lista, a na izlazu daje predikciju jedne od mogućih kategorija iz skupa zdravih ili bolesnih biljaka.

2. Motivacija problema rešavanog u projektu

Globalna poljoprivredna proizvodnja se neprestano suočava sa gubicima usled kasnog otkrivanja biljnih bolesti, što direktno ugrožava stabilnost snabdevanja hranom. Motivacija za ovaj projekat proizilazi iz potrebe da se omogući poljoprivrednicima rano otkrivanje bolesti. Razvojem ovakvog sistema omogućava se trenutna dijagnostika, čime se smanjuje potreba za preventivnim korišćenjem pesticida i omogućava ciljano delovanje na zaražene površine.

3. Relevantna literatura

3.1. Plant leaf disease detection and classification using convolution neural networks model: a review

Tema rada: Ovaj rad predstavlja sveobuhvatan pregled savremenih metoda dubokog učenja za detekciju i klasifikaciju bolesti biljaka na osnovu slika listova. Autori analiziraju razvoj oblasti, najčešće korišćene arhitekture neuronskih mreža, skupove podataka i izazove u realnoj primeni sistema za automatsku dijagnostiku biljnih bolesti.

Podaci: U radu su analizirani brojni javno dostupni skupovi podataka, među kojima se najviše ističe *PlantVillage* dataset, koji sadrži desetine hiljada anotiranih slika zdravih i obolelih listova različitih biljnih vrsta. Takođe se razmatraju i realni skupovi podataka prikupljeni u prirodnim uslovima, sa neujednačenim osvetljenjem i kompleksnom pozadinom.

Metodologija: Rad ne uvodi novi model, već sistematski analizira postojeće pristupe. Poseban fokus stavljen je na konvolucione neuronske mreže (*CNN*), kao što su *AlexNet*, *VGG*, *ResNet*, *DenseNet* i *EfficientNet*. Autori razmatraju i tehnike *transfer learning*, augmentaciju podataka, kao i poređenje klasičnih metoda obrade slike sa savremenim *deep learning* pristupima.

Evaluacija rešenja: Evaluacija je izvedena kroz poređenje rezultata iz različitih istraživanja. Kao glavne metrike navode se tačnost (*accuracy*), preciznost, odziv i F1-mera. Zaključeno je da modeli bazirani na *deep learning* u većini slučajeva značajno nadmašuju tradicionalne metode, posebno kada se koristi *transfer learning*.
Zaključak: Rad daje jasan uvid u trenutno stanje istraživanja u oblasti detekcije bolesti biljaka pomoću slika. Posebno je značajan jer ukazuje na probleme generalizacije modela u realnim uslovima i potrebu za raznovrsnijim skupovima podataka. Ovaj pregled je dobra teorijska osnova za naš rad, jer pomaže u izboru odgovarajuće *CNN* arhitekture i metodologije treniranja.

3.2. Plant Disease Detection Using Convolutional Neural Networks

Tema rada: Rad se bavi automatskom detekcijom i klasifikacijom bolesti biljaka korišćenjem konvolucionih neuronskih mreža. Cilj istraživanja je da se pokaže da CNN modeli mogu efikasno prepoznati različite bolesti listova na osnovu vizuelnih karakteristika.
Podaci: Korišćen je skup podataka koji se sastoji od slika zdravih i obolelih listova različitih biljnih vrsta. Slike su prethodno anotirane i podeljene u klase koje odgovaraju konkretnim bolestima. Skup podataka je srednje veličine i pogodan za treniranje *CNN* modela uz augmentaciju.
Metodologija: Autori su primenili klasičnu *CNN* arhitekturu sa više konvolucionih i *pooling* slojeva, nakon čega slede potpuno povezani slojevi za klasifikaciju. Pre treniranja izvršena je normalizacija i promena dimenzija slika. Model je treniran od početka (bez *transfer learning* metode), čime se ispituje sposobnost *CNN* modela da sam nauči relevantne karakteristike bolesti.
Evaluacija rešenja: Evaluacija je izvršena pomoću tačnosti klasifikacije nad test skupom. Rezultati pokazuju visoku preciznost u prepoznavanju bolesti, što potvrđuje da *CNN* može uspešno naučiti razlike u teksturi, boji i oblicima promena na listovima.
Zaključak: Rad potvrđuje efikasnost konvolucionih neuronskih mreža u problemima detekcije biljnih bolesti. Iako je korišćena jednostavnija arhitektura u poređenju sa savremenim modelima, rezultati su dobri. Ovaj rad je relevantan za naš projekat jer pokazuje osnovni *CNN* pristup koji se može unaprediti korišćenjem *transfer learning* metode i naprednijih arhitektura.

3.3. Plant Disease Detection Using Deep Convolutional Neural Network

Tema rada: Ovaj rad se fokusira na primenu *deep learning* tehnika za prepoznavanje bolesti biljaka analizom slika listova. Cilj je razvoj sistema koji može pomoći poljoprivrednicima u ranom otkrivanju bolesti i smanjenju gubitaka u prinosu.

Podaci: Skup podataka sadrži slike listova različitih biljaka, podeljene na više klasa bolesti, kao i klasu zdravih biljaka. Slike su prikupljene u kontrolisanim uslovima i ručno anotirane, što omogućava pouzdano treniranje modela.

Metodologija: U radu su korišćeni modeli konvolucionih neuronskih mreža uz primenu *transfer learning* metode. Prethodno trenirani modeli su dotrenirani na skupu slika biljnih bolesti. Poseban akcenat stavljen je na ekstrakciju karakterističnih vizuelnih obrazaca, kao što su promene boje, mrlje i deformacije listova.

Evaluacija rešenja: Performanse modela procenjene su pomoću tačnosti i gubitka (*loss*). Eksperimentalni rezultati pokazuju da modeli sa *transfer learning* metodom postižu bolju stabilnost i veću tačnost u poređenju sa modelima treniranim od nule.

Zaključak: Rad pokazuje da je *transfer learning* veoma efikasan pristup u problemima detekcije bolesti biljaka, naročito kada je količina podataka ograničena. Ovo je direktno primenljivo na naš rad, jer omogućava korišćenje prethodno treniranih modela i postizanje dobrih rezultata uz manji skup podataka.

4. Skup podataka

Za razvoj i obuku modela koristiće se javno dostupan skup podataka pod nazivom „*New Plant Diseases Dataset*“ sa *Kaggle* sajta. Ovaj skup podataka sadrži preko 87.000 slika koje su podeljene u 38 različitih klasa, pokrivajući četrnaest različitih vrsta biljaka poput paradajza, krompira, jabuke, grožđa i kukuruza. Podaci su organizovani tako da uključuju slike potpuno zdravih listova, kao i onih pogođenih specifičnim bolestima, što omogućava modelu da nauči da prepozna razliku između zdravih i obolelih biljaka. Od ukupno 38 klasa za trening, 26 klasa predstavlja različite biljne bolesti, poput bakterijske pegavosti, rane i kasne plamenjače, pepelnice i crne truleži, dok preostalih 12 klasa odgovaraju zdravim stanjima listova za pojedine biljne vrste. Takođe, za neke vrste biljaka postoje slike samo zdravih listova, s toga će te klase biti isključene. Svaka slika je standardizovana na rezoluciju od 256×256 piksela u tri kanala boja, a ukupna veličina skupa podataka od oko 3 *GB* obezbeđuje dovoljnu količinu podataka za treniranje kompleksnih neuronskih mreža. Iako dataset obuhvata veliki broj uzoraka, nije potpuno balansiran, jer broj slika po klasama varira, što je uobičajeno za realne skupove podataka i može se ublažiti primenom tehnika poput ponderisanja klasa ili augmentacije podataka tokom treniranja.

5. Metodologija

Metodološki pristup se oslanja na primenu dubokih konvolucionih neuronskih mreža (*CNN*) koje su se pokazale kao najefikasnije rešenje za ekstrakciju prostornih karakteristika iz slika. U projektu će se primeniti tehnika *transfer learning*, što podrazumeva korišćenje arhitektura poput *ResNet50*, *VGG16 i EfficientNet*. *ResNet50* arhitektura je posebno značajna zbog uvođenja rezidualnih veza koje omogućavaju gradijentu da lakše prolazi kroz duboke slojeve neuronske mreže, čime se izbegava problem nestajanja gradijenta i omogućava brža konvergencija.

Tehnička realizacija obuhvata proces predobrade (*preprocessing*) gde se primenjuje augmentacija podataka u vidu nasumičnih rotacija, horizontalnog prevrtanja i varijacija u osvetljenju, čime se veštački povećava raznolikost skupa i sprečava preterano prilagođavanje modela specifičnim uslovima u kojima su slike nastale. Za optimizaciju funkcije gubitka, koja će biti definisana kao *categorical cross-entropy*, koristiće se *Adam* optimizator jer kombinuje prednosti adaptivnog učenja po parametru i momentu. Model će biti implementiran korišćenjem PyTorch biblioteka, uz korišćenje lokalnog *GPU* ili *Google Colab GPU* ubrzanja za intenzivne proračune konvolucionih operacija.

Proširenje projekta bi moglo da se zasniva na postavljanju različitih upita nad skupom podataka kako bi bile izvučene određene karakteristike iz samo skupa.

6. Metod evaluacije

Celokupan skup podataka biće podeljen na tri različita skupa: trening skup koji obuhvata 80% podataka, validacioni skup od 20% koji služi za podešavanje parametara tokom obuke, i odvojeni testni skup na kojem će se vršiti konačna provera. Primarna metrika uspešnosti biće ukupna tačnost klasifikacije, ali će se poseban akcenat staviti na analizu matrice konfuzije, jer omogućava identifikaciju specifičnih parova klasa koje model često meša. Pored toga, izračunavaće se preciznost, odziv i *F1-score* za svaku klasu pojedinačno kako bi se osiguralo da model podjednako dobro detektuje i retke bolesti koje su zastupljene sa manjim brojem primera u skupu podataka.